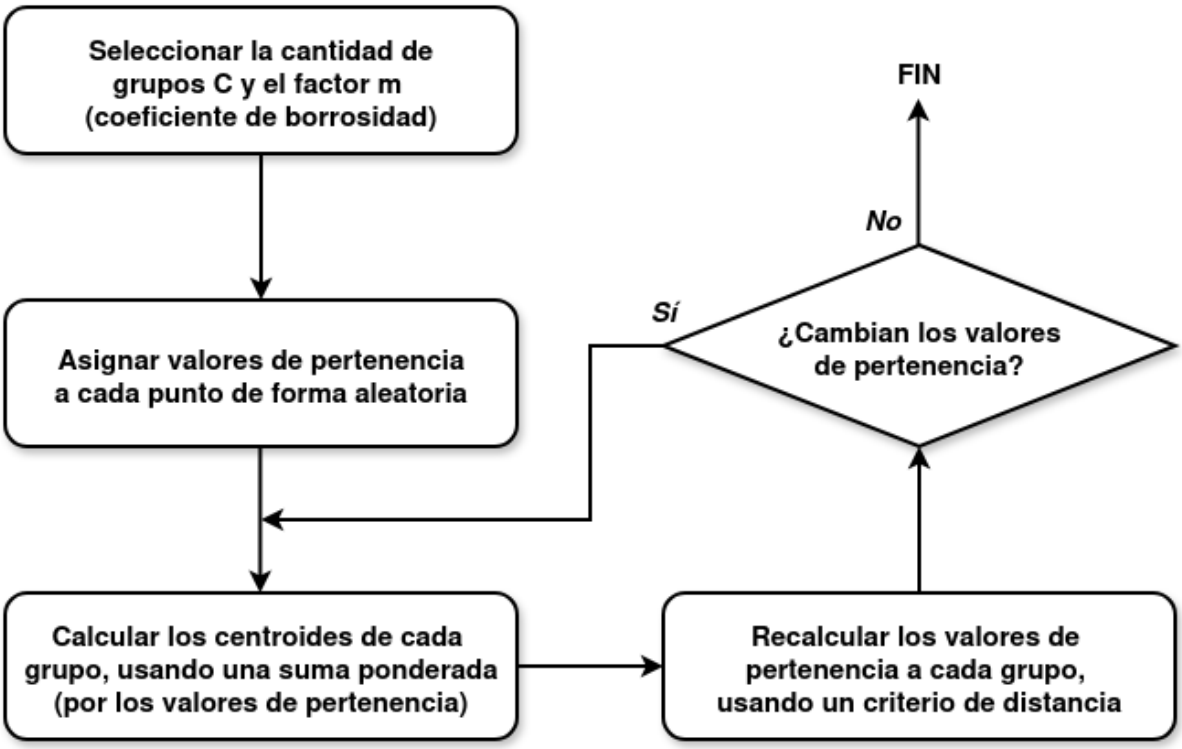
Agrupamiento (Clustering) C-Means difuso

Se trata de un método de agrupamiento que permite la pertenencia simultánea de un punto de datos a diferentes grupos, con grados de pertenencia (*membership*) diferenciados. La frontera entre grupos llega a ser borrosa en principio, pero la propia distribución de los datos termina definiendo una selección adecuada de los valores de pertenencia de los diferentes elementos del universo de datos.



¿Qué representa el factor de borrosidad (m)?

m representa el grado permitido de solapamiento entre los diferentes grupos que componen el universo de datos. Representa también qué tan difusas o suaves son las fronteras entre los dieferentes grupos, lo que diferencia este método de otros en donde la pertenencia a un grupo es estrictamente exclusiva (como el k-means).

¿Cómo se calcula el centroide de cada uno de los grupos?

El centroide de cada grupo debe actualizarse iterativamente, de acuerdo con la siguiente expresión:

$$v_i = \frac{\sum_{k=1}^{n} (\mu_k)^m \cdot x_k}{\sum_{k=1}^{n} (\mu_k)^m}$$

Donde:

- v_i es el centroide del grupo i.
- n es la cantidad de puntos (datos) a agrupar.
- μ_k es el grado de pertenencia del k-ésimo punto al grupo i.
- x_k corresponde a las coordenadas del dato k-ésimo.
- m es el factor de borrosidad. Debe ser mayor a la unidad (usualmente $m=2$).

¿Cómo se actualizan los diferentes valores de pertenencia (membership)?

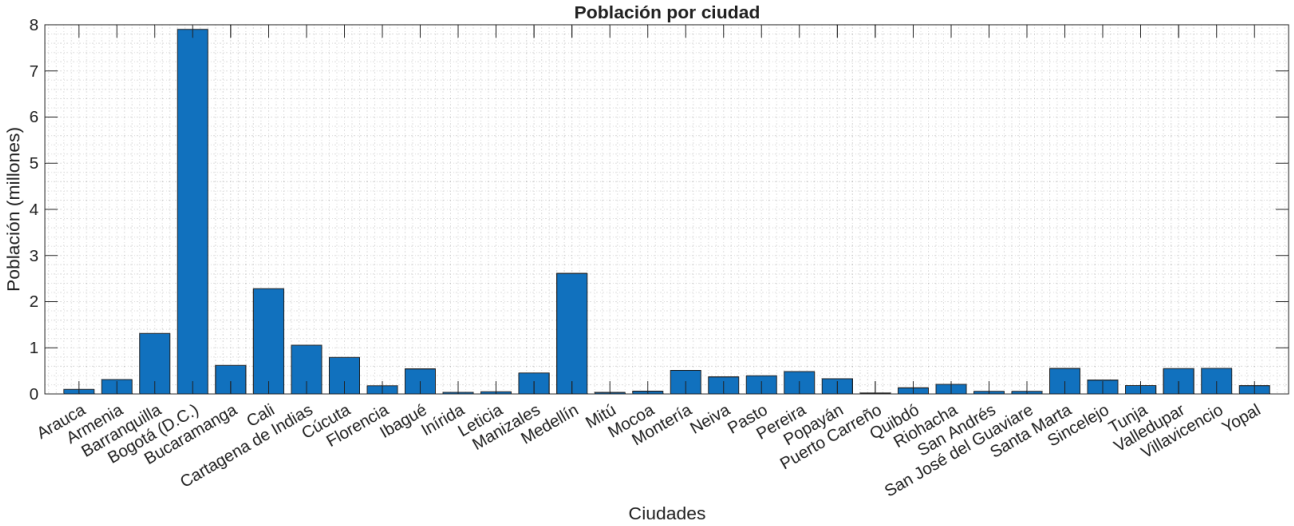
Para cada punto de datos x_i y cada grupo (clúster) j, el nuevo grado de pertenencia se calcula de la siguiente manera:

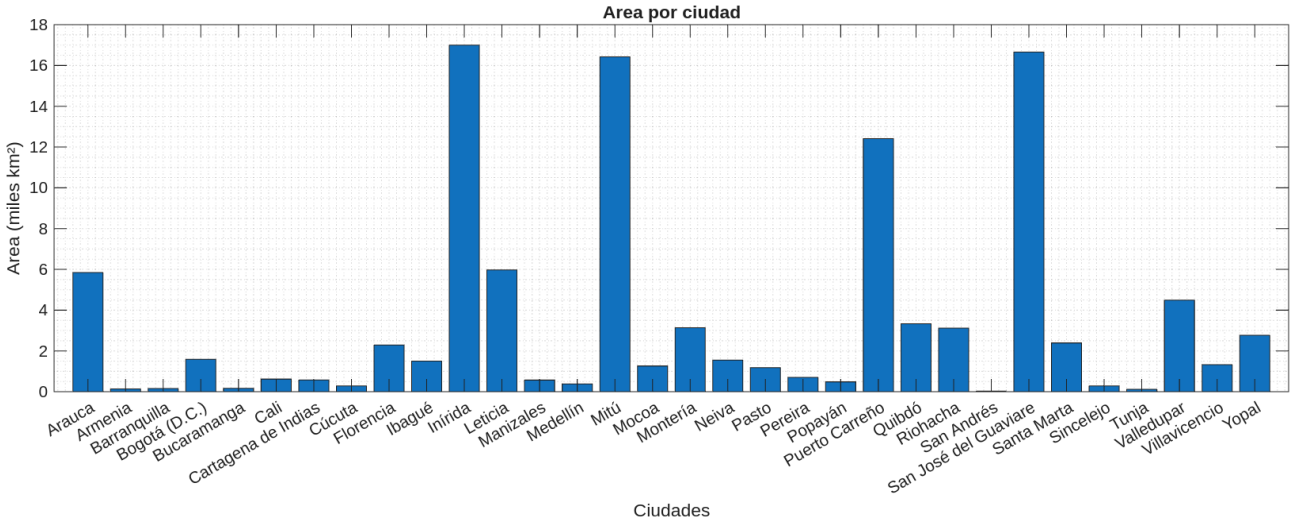
$$\mu_{ij} = \frac{1}{\sum_{k=1}^{C} \left(\frac{d_{ij}}{d_{ik}} \right)^{\frac{2}{m-1}}}$$

Donde:

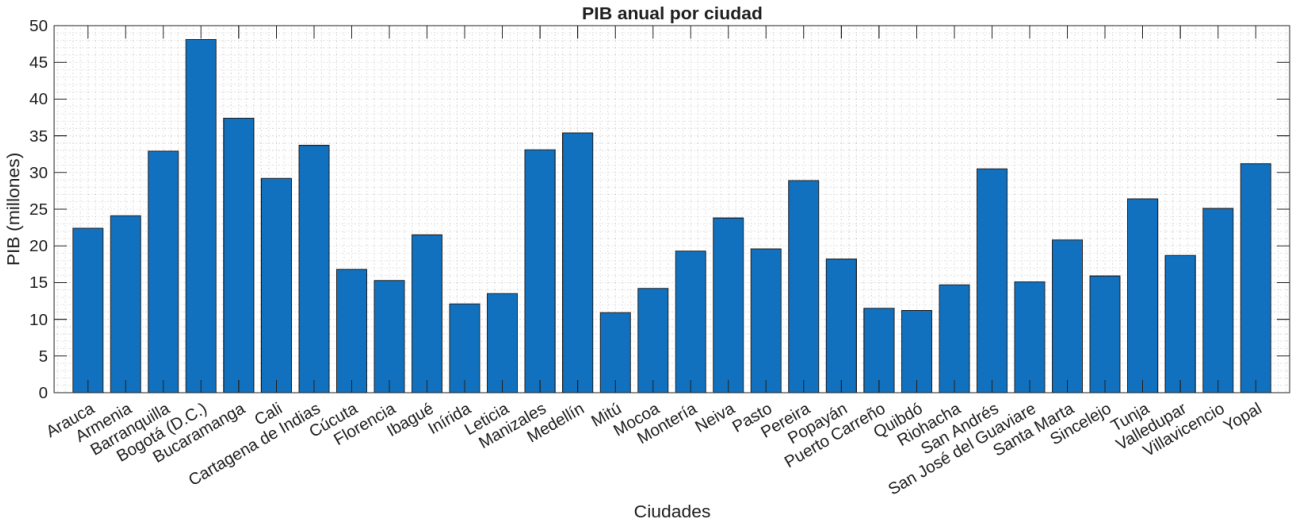
- C es la cantidad de grupos (clústers) considerados en el algoritmo.
- d_{ij} es la distancia (usualmente la euclidiana) entre el punto x_i y el clúster v_j.
- d_{ik} es la distancia entre el punto x_i y cada clúster v_k.
- m es el factor de borrosidad. Debe ser mayor a la unidad (usualmente $m = 2$).

Ejemplo: Agrupando ciudades por medio de tres (3) características diferentes[1]

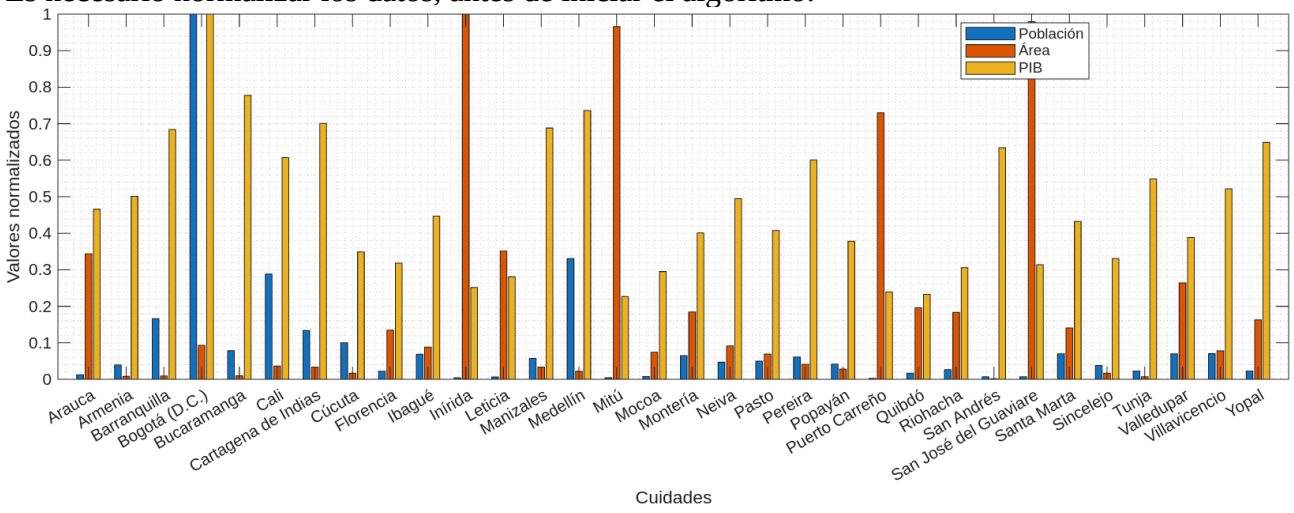




1 Datos tomados del DANE



Es necesario normalizar los datos, antes de iniciar el algoritmo:



Luego de ejecutar el algoritmo para 4 grupos:

