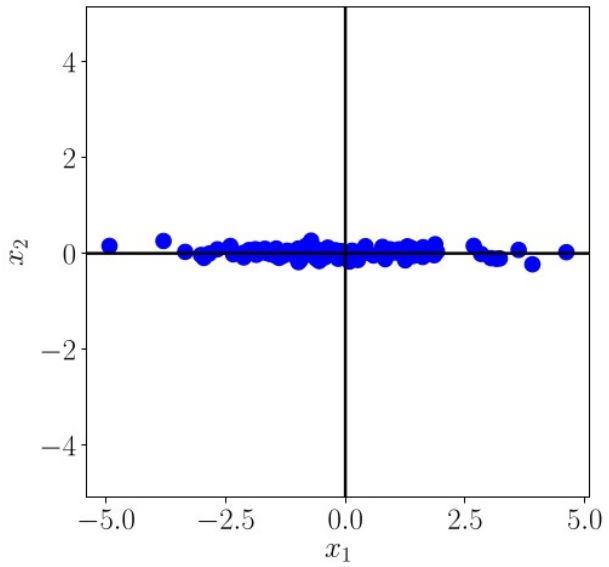
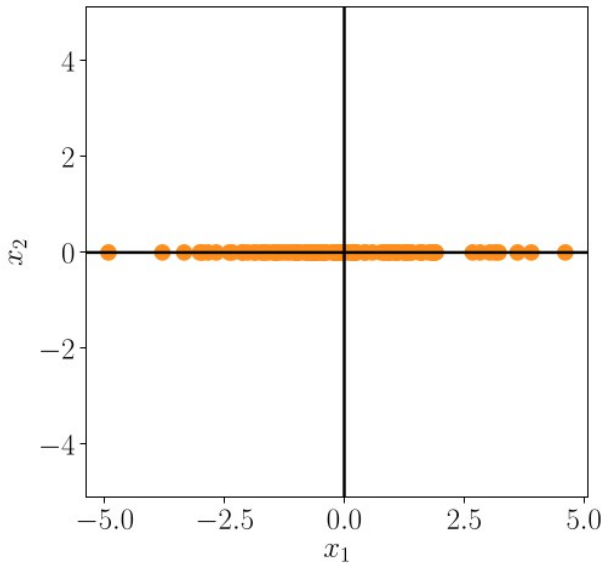
PCA: Análisis de componentes principales (transformada Karhunen-Loéve)



(a) Dataset with x_1 and x_2 coordinates.



(b) Compressed dataset where only the x_1 coordinate is relevant.

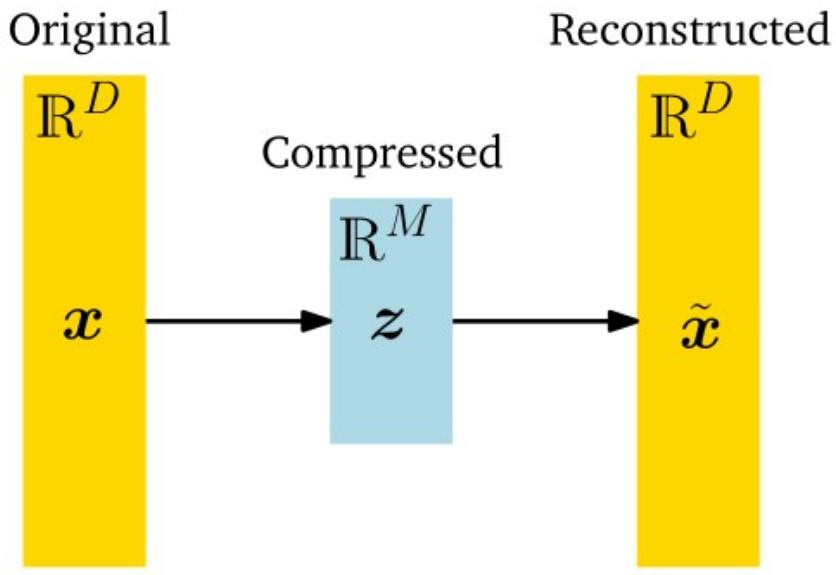
Planteamiento:

Dado un conjunto de datos definidos por x_n, la intención es encontrar una representación o proyección alternativa, llamada $\widetilde{x_n}$, que tenga menores dimensiones, pero que aproxime de la mejor manera la información contenida en el conjunto de datos original. Se define la matriz de covarianza de cada dato x_n como:

$$\boldsymbol{S}=\frac{1}{N}\sum_{n=1}^{N}\boldsymbol{x_n}\cdot\boldsymbol{x_n^T}$$

Condiciones para los datos:

- El conjunto de datos debe ser IID (Independiente y distribuido idénticamente).
- Los datos deben tener promedio nulo.

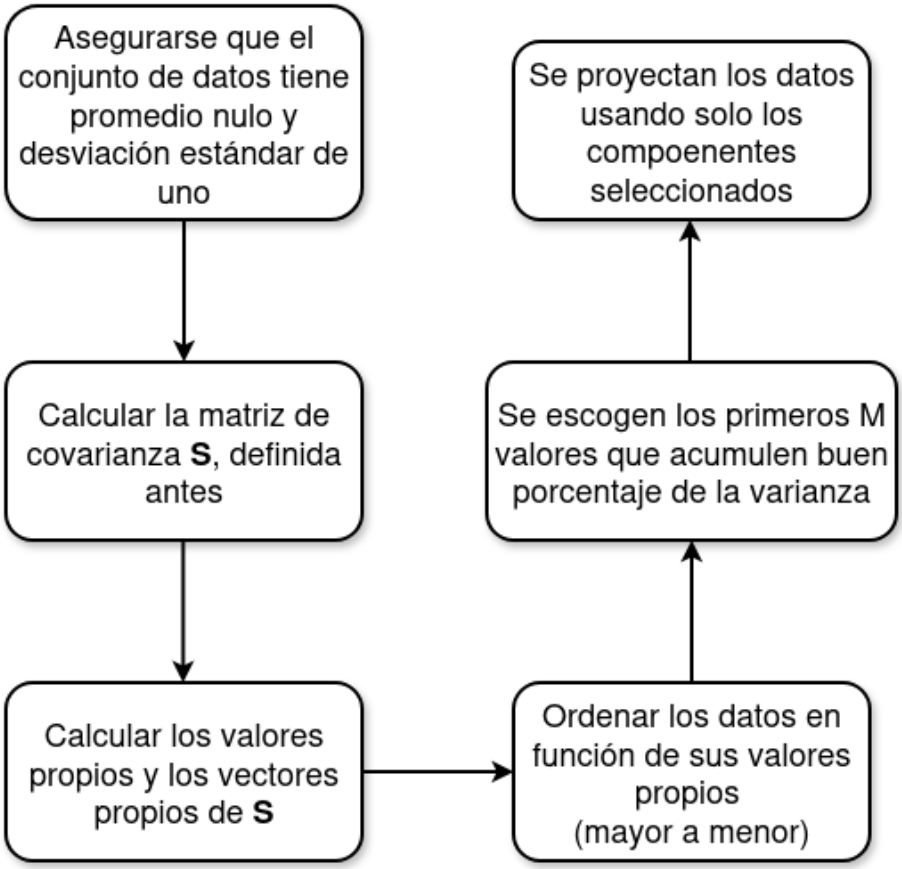


Se define una representación comprimida:

$$\boldsymbol{z_n} = \boldsymbol{B}^T \cdot \boldsymbol{x_n} \in \mathbb{R}^M \text{; Siendo: } M < N$$

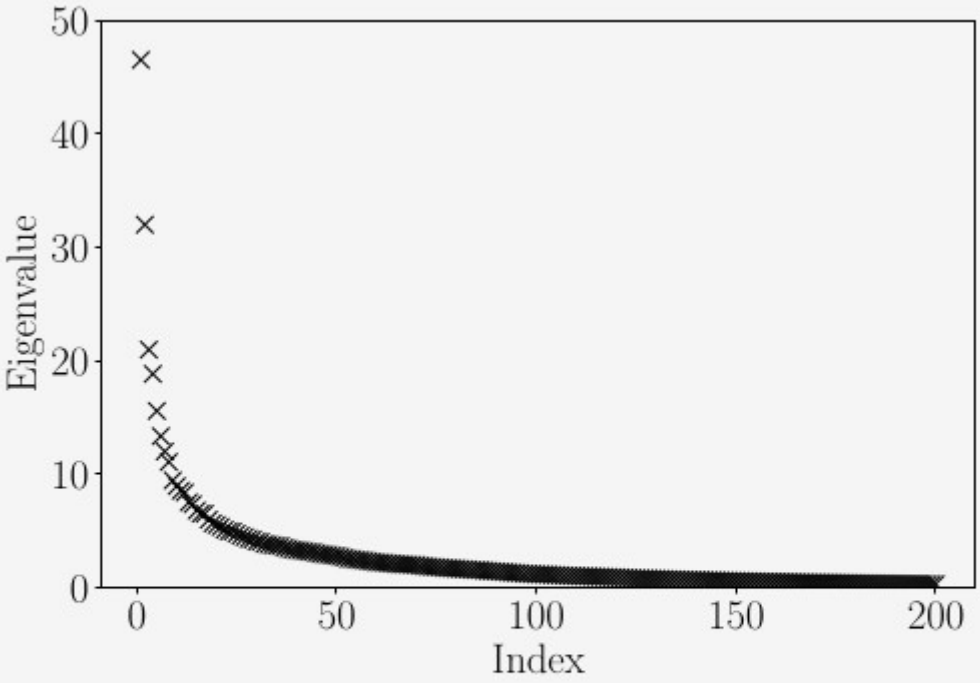
La matriz $\boldsymbol{B}$ es referida como la *matriz de proyección*, y permite calcular un código representativo o comprimido para los datos originales (z_n), y/o una proyección de dicho código en el espacio de datos original ($\widetilde{x}_n$), pero despreciando o eliminando algunas dimensiones. El objetivo del proceso es reducir al máximo las *pérdidas de compresión*, y esto se logra *maximizando la varianza* de los datos comprimidos.

Algoritmo



Tarea: Conjunto de datos MNIST





(a) Eigenvalues (sorted in descending order) of the data covariance matrix of all digits “8” in the MNIST training set.

Datos disponibles en:
https://www.kaggle.com/datasets/hojjatk/mnist-dataset