Machine Learning: Regresión *vs.* Clasificación

En los problemas de clasificación el objetivo es definir regiones de decisión o fronteras de decisión para determinar la pertenencia a alguna de las clases. K sería la cantidad de clases, y C_k cada una de dichas clases. Cuando $K=2$ se puede hablar de esquemas de *pertenencia si/no* a una clase determinada (por ejemplo, en problemas de detección). En todoc aso, se puede optar por varias estrategias:

- Discriminantes
- Inferencia + Decisión basada en alguna distribución.
- Usar el teorema de Bayes:

$$p(C_k|\boldsymbol{x})=\frac{p(\boldsymbol{x}|C_k)\cdot p(C_k)}{p(\boldsymbol{x})}$$

En esquemas de *regresión lineal*, la salida del modelo se calcula como una combinación lineal de los valores de entrada, y un valor independiente (sesgo, *BIAS*):

$$y_r(\boldsymbol{x})=\boldsymbol{w}^T\cdot\boldsymbol{x}+w_0$$

Donde los valores de los pesos ($\boldsymbol{w}$) y el sesgo (w_0) se ajustan de manera óptima, luego de un proceso de entrenamiento. En esquemas de clasificación, es necesario agregar una *función de activación*, que aproxime mejor un comportamiento binario de la salida. La salida de un modelo de clasificación se puede calcular entonces como:

$$y_c(\boldsymbol{x})=f(\boldsymbol{w}^T\cdot\boldsymbol{x}+w_0)$$

Si hubiera un problema multiclase ($K>2$), se acostumbra manejar un conjunto de modelos binarios que generan salidas del tipo (por ejemplo, para $K=5$): $y_c(\boldsymbol{x})=[0,0,1,0,0]$. A veces se activan varias salidas en un problema en el que las clases son mutuamente excluyentes, de diferentes modelos a la vez, en cuyo caso es necesario definir un mecanismo para agregar las salidas individuales.

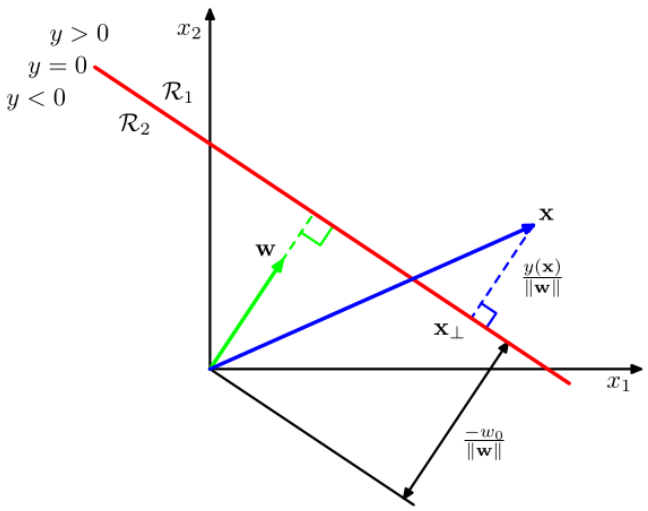
Discriminantes

La solución más simple: Discriminante lineal.

Si $\boldsymbol{w}^T\cdot\boldsymbol{x}+w_0>0$ se asigna la clase C_1 a la salida.

En caso contrario se asigna la otra clase (C_2 o $\widetilde{C}_1$)

En este caso al negativo de w_0 se le llama el umbral de decisión.



Para $K>2$ se puede trabajar comparando la salida de múltiples clasificadores, de tal manera que si:

$$\boldsymbol{w}_j^T \cdot \boldsymbol{x} + w_{j0} > \boldsymbol{w}_k^T \cdot \boldsymbol{x} + w_{k0}$$

La clase de salida sería la clase j.

Otro ejemplo: Discriminante basado en perceptrón

$$y_c(\boldsymbol{x}) = f\left(\boldsymbol{w}^T \cdot \phi(\boldsymbol{x})\right)$$

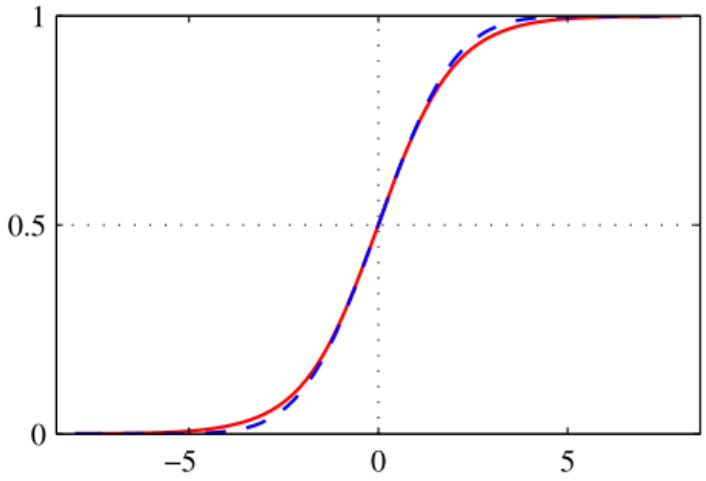
Donde: $\phi(\boldsymbol{x})$ representa una transfrmación no-lineal sobre $\boldsymbol{x}$.

La función de activación se puede implementar de la forma:

$$f(a) = \begin{cases} 1; \text{ Si } a \geq 0 \\ 0; \text{ Si } a < 0 \end{cases}$$

Función Sigmoidal Logística ($K=2$)

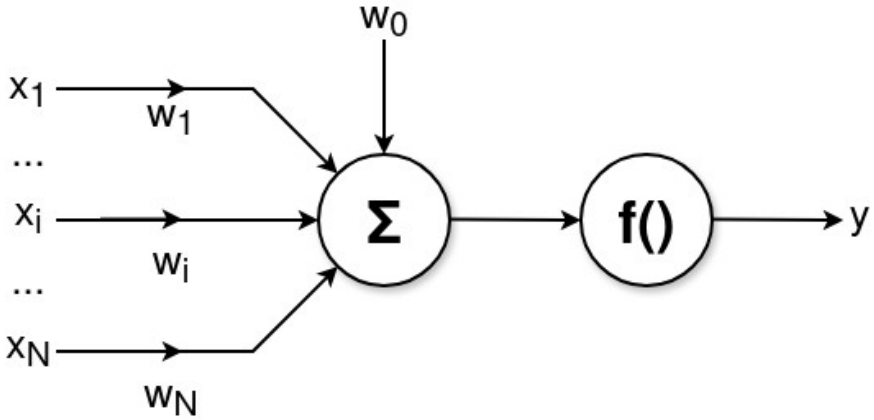
$$\sigma(a) = \frac{1}{1+e^{-a}}$$



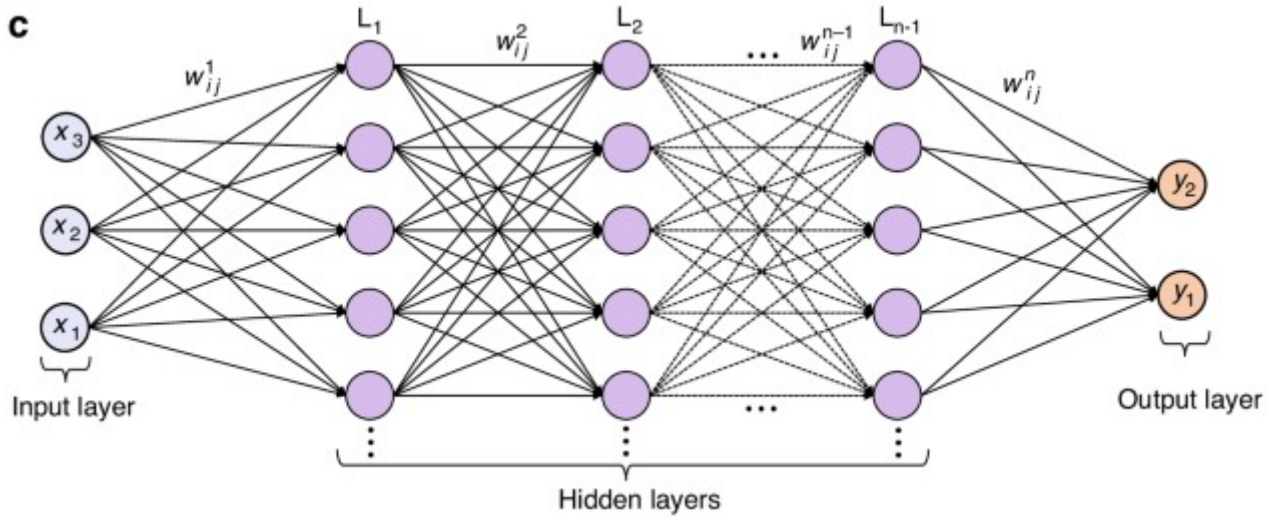
Para un problema multiclases ($K>2$) se implementa una función de activación exponencial normalizada (*SoftMax*):

$$p(C_k|\boldsymbol{x}) = \frac{e^{a_k}}{\sum_j e^{a_j}}$$

El Perceptrón



MLP: Perceptrón Multi-Capa



Se ditinguen 3 procesos:

1. Entrenamiento
2. Validación
3. Prueba