PROCESAMIENTO INTELIGENTE DE SEÑALES

Valores de Shapley

Explicar un modelo de aprendizaje y simplificarlo

Daniel Osorio

Universidad Nacional de Colombia · Sede Medellín

DEFINICIÓN

¿Qué son los valores de Shapley?

No son un clasificador: explican cualquier clasificador o regresor ya entrenado.

El modelo

SVM, árbol, ensamble, red neuronal... Recibe $x = (x_1, ..., x_D)$ y entrega una predicción $f(x)$.

Los valores de Shapley

Reparten esa predicción entre las variables: cuánto aportó cada x_i la salida hacia arriba o hacia abajo.

La pregunta que responden: **¿por qué el modelo dijo esto?**

EL ORIGEN

Viene de la teoría de juegos cooperativos

En el juego	En el modelo
Jugadores (i)	Variables de entrada
Coalición S	Subconjunto de variables conocidas
Ganancia v(S)	Predicción esperada usando solo S
Reparto justo φ_i	Aporte de la variable i

Valor de Shapley de la variable i

$$\varphi_i = \sum w(S) \cdot [\, v(S \cup \{i\}) - v(S) \,]$$

La suma recorre todo $S \subseteq F \setminus \{i\}$, con peso
$w(S) = |S|!\,(D - |S| - 1)! \,/\, D!$

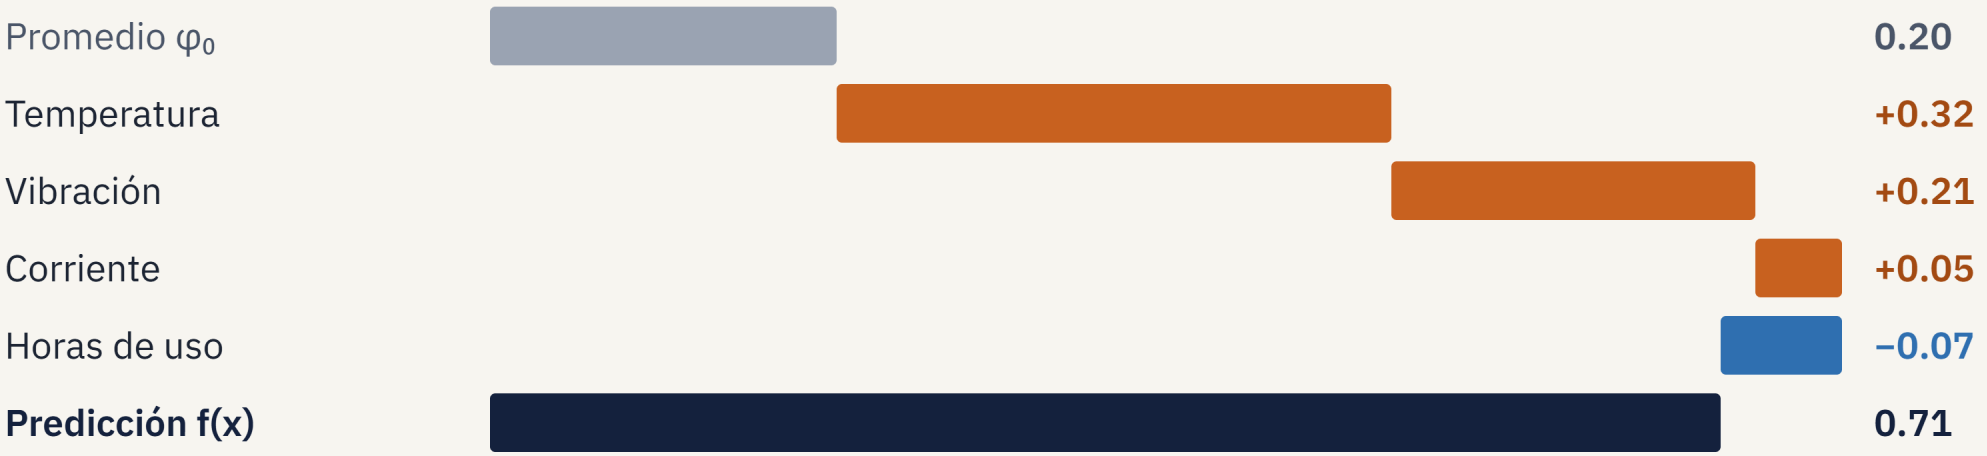
Es el promedio de lo que **agrega x_i** sobre todos los órdenes en que las variables pueden “entrar” al modelo.

LA PROPIEDAD CLAVE

Cada predicción se reparte exactamente

$$f(x) = \varphi_0 + \varphi_1 + \varphi_2 + \ldots + \varphi_D$$

φ_0 = predicción promedio sobre los datos. Ejemplo Probabilidad de falla de un motor.



EN LA PRÁCTICA

En MATLAB: la función shapley

```
% 1. Entrenar cualquier modelo
mdl = fitcensemble(Xtrain, Ytrain);

% 2. Explicarlo en datos de validación
ex = shapley(mdl, Xtrain, QueryPoints=Xval);

% 3. Ver resultados
ex.Shapley % ψ por punto y clase
ex.MeanAbsoluteShapley % importancia
plot(ex) % barras de mean|ψ|
swarmchart(ex, ClassName="1")
```

El algoritmo depende del modelo

Linear SHAP · exacto
Modelos lineales y SVM lineal

Tree SHAP · exacto
Árboles y ensambles de árboles

Kernel SHAP · aproximado
Cualquier modelo, incluso una función

Desde R2021a. Varios puntos y MeanAbsoluteShapley desde R2024a; antes de R2024b la tabla se llamaba ShapleyValues.

COMPARACIÓN

PCA y Shapley reducen dimensiones distinto

	PCA	Shapley
¿Usa la salida y?	No: no supervisado	Sí: explica un modelo entrenado
Qué obtiene	Nuevas variables $z = B^T x$	Un peso φ_i por variable original
Criterio	Máxima varianza de los datos	Aporte a la predicción
Al reducir	Proyecta en M componentes	Conserva las k variables más útiles
Interpretable	Poco: z_1 mezcla todos los píxeles	Sí: quitas variables o sensores reales
Costo	Un problema de valores propios	Muchas evaluaciones del modelo

Se complementan: PCA comprime la entrada; Shapley dice qué entrada importa para la decisión.

APLICACIÓN

Simplificar un modelo en cinco pasos

1

Entrena el modelo con todas las variables

2

Calcula φ en un conjunto de validación

3

Importancia global: promedio de $|\varphi_i|$

4

Ordena y conserva las k más importantes

5

Reentrena con k variables y compara la exactitud

```
imp = mean(ex.MeanAbsoluteShapley{:,2:end}, 2); % promedio sobre clases
[~, orden] = sort(imp, "descend");
sel = orden(1:k);
mdlSimple = fitcensemble(Xtrain(:,sel), Ytrain);
```

ANTES DE CONFIAR EN EL RESULTADO

Tres cuidados al usar Shapley

Costo de cálculo

Con D variables hay 2^D subconjuntos. MATLAB aproxima con Kernel SHAP (MaxNumSubsets) y toma 100 observaciones de fondo por defecto.

Variables correlacionadas

El crédito se reparte entre variables parecidas y ambas pueden parecer poco importantes.

Explica el modelo, no la física

Si el modelo aprendió algo espurio, Shapley lo mostrará fielmente. Por lo que siempre se necesita validar siempre con datos de prueba.