PROCESAMIENTO INTELIGENTE DE SEÑALES

K vecinos más cercanos

KNN: clasificar por similitud

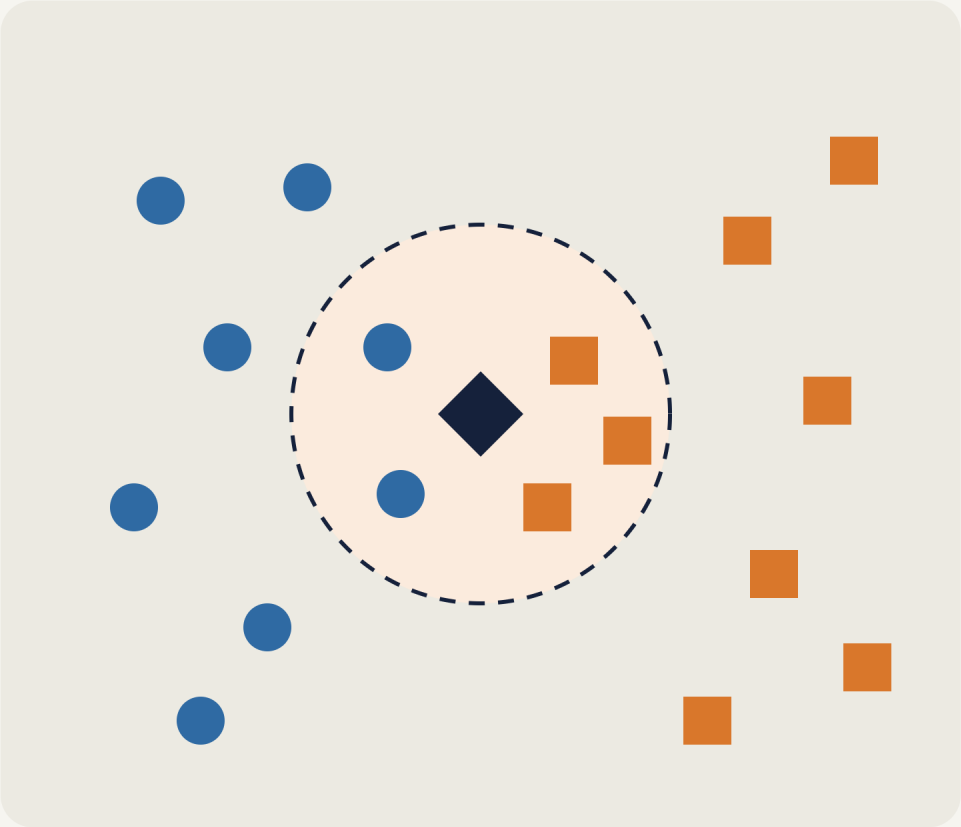
Daniel Alexis Osorio Osorio · Universidad Nacional de Colombia, sede Medellín

LA IDEA

Dime con quién andas y te diré quién eres

Una muestra nueva toma la clase que más se repite entre sus **K vecinos más cercanos** del conjunto de entrenamiento.

En la figura, con K = 5 hay 3 cuadrados y 2 círculos dentro del círculo punteado: la muestra se clasifica como **clase B**.



● Clase A (círculos) · ■ Clase B (cuadrados) · ◆ Muestra nueva

Cómo predice: cuatro pasos

1

Estandarizar

Cada característica queda con media 0 y desviación 1.

$$z = (x - \mu) / \sigma$$

2

Medir distancias

De la muestra a cada punto guardado.

$$d = \sqrt{\Sigma\ (x_j - x'_j)^2}$$

3

Tomar K vecinos

Ordenar las distancias y quedarse con las K menores.

4

Votar

Gana la clase que más se repite entre los K vecinos.

Esto se repite para cada muestra nueva. No hay pesos ni iteraciones: todo el cálculo ocurre **al predecir**.

Fundamento matemático

$$\hat{y}(x) = \arg\max \Sigma\, 1[y_i = c]$$

Regla de decisión. La suma recorre los K vecinos de x y el máximo se busca sobre las clases c: gana la clase con más votos.

$$P(c \mid x) \approx k(c) / K$$

Lectura probabilística. La fracción de vecinos de la clase c estima su probabilidad; votar equivale a elegir la clase más probable, como el clasificador de Bayes.

$$\text{error(1-NN)} \leq 2 \cdot \text{error(Bayes)}$$

Garantía con infinitos datos (Cover y Hart, 1967). Si K crece pero K/N → 0, KNN tiende al clasificador óptimo.

¿Y el entrenamiento? Casi no existe

AL LLAMAR FIT

- Guarda los datos de entrenamiento y sus etiquetas
- Calcula μ y σ de cada característica
- Construye un árbol KD para buscar vecinos rápido

AL LLAMAR PREDICT

- Estandariza la muestra con μ y σ guardados
- Busca los K vecinos; el árbol descarta ramas lejanas sin revisarlas
- Cuenta los votos y devuelve la clase ganadora

Aprendizaje perezoso

Entrenar es casi gratis; predecir es lo costoso. El modelo ocupa tanta memoria como los datos.

Ejemplo: una flor del conjunto de prueba

LA MUESTRA

Sépalo: 5,6 × 2,8 cm
Pétalo: 4,9 × 2,0 cm

Estandarizada: (−0,32; −0,63; 0,62; 1,03)

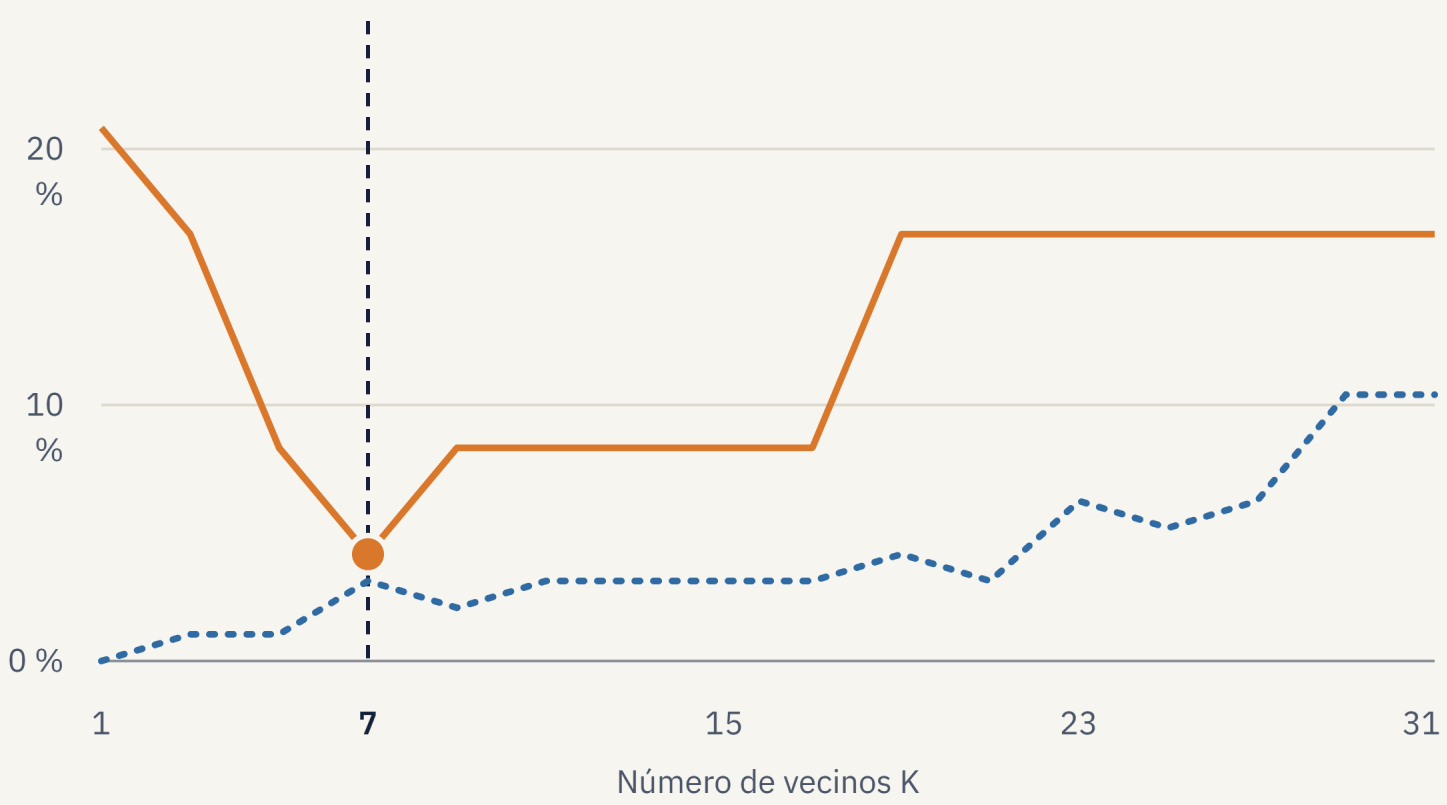
Clase real: **virginica**. El modelo no la conoce.

6 votos virginica, 1 versicolor: predice virginica

Sus 7 vecinos más cercanos (K = 7)

1	virginica	d = 0,38
2	virginica	d = 0,38
3	virginica	d = 0,58
4	virginica	d = 0,66
5	virginica	d = 0,73
6	**versicolor (en minoría)**	d = 0,75
7	virginica	d = 0,76

Elegir K con el conjunto de validación



K = 1: entrenamiento 0 %, validación 21 %. Sobreajuste.

K = 7: mínimo de validación, 4,2 %. Es el K elegido.

K ≥ 19: la frontera se suaviza demasiado; validación 16,7 %.

¿Por qué K impar?

Dos clases

2 – 2

K = 4: empate, el modelo no puede decidir

3 – 2

K = 5: con K impar siempre hay mayoría

Tres o más clases

3 – 3 – 1

K = 7: el empate sigue siendo posible

Desempate: scikit-learn y MATLAB eligen la primera clase en su orden. Alternativas: ponderar por distancia (1/d) o usar la clase del vecino más cercano.

Consideraciones prácticas

Escalar siempre

Sin estandarizar, la variable con mayor rango domina la distancia.

Elegir la métrica

Euclidiana por defecto; Manhattan, coseno o voto ponderado según los datos.

Pocas dimensiones

Con muchas variables las distancias se parecen; reducir antes, por ejemplo con PCA.

Costo al predecir

Cada consulta recorre los datos guardados; lento con millones de muestras.

Clases balanceadas

Una clase mucho más numerosa tiende a ganar las votaciones.

Variables útiles

Las irrelevantes pesan igual que las útiles en la distancia.

RESULTADO EN IRIS

29 de 30 flores de prueba bien clasificadas

K = 7
Vecinos, elegido por validación

96,7 %
Accuracy

97,0 %
Precisión (promedio)

96,7 %
F1-score (promedio)

Único error: una **virginica** clasificada como **versicolor**. Setosa nunca se confunde.

Partición estratificada: 96 entrenamiento · 24 validación · 30 prueba · semilla 1

En resumen

1. KNN clasifica por mayoría entre los K vecinos más cercanos.
2. No aprende pesos: guarda los datos y hace el trabajo al predecir.
3. Funciona bien con pocas dimensiones, datos escalados y un K elegido por validación.